

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ
по лабораторной работе №3
по дисциплине «Построение и анализ алгоритмов»
Тема: Расстояние Левенштейна
Вариант: 4б

Студентка гр. 3343

Лобова Е. И.

Преподаватель

Жангиров Т. Р.

Санкт-Петербург

2025

Цель работы

Целью работы является изучение задачи о редакционном расстоянии, алгоритма Вагнера-Фишера и расстояния Левенштейна.

Задание

Задание 1

Над строкой ϵ (будем считать строкой непрерывную последовательность из латинских букв) заданы следующие операции:

1. $\text{replace}(\epsilon, a, b)$ – заменить символ a на символ b .
2. $\text{insert}(\epsilon, a)$ – вставить в строку символ a (на любую позицию).
3. $\text{delete}(\epsilon, b)$ – удалить из строки символ b .

Каждая операция может иметь некоторую цену выполнения (положительное число).

Даны две строки A и B , а также три числа, отвечающие за цену каждой операции. Определите минимальную стоимость операций, которые необходимы для превращения строки A в строку B .

Входные данные: первая строка – три числа: цена операции replace , цена операции insert , цена операции delete ; вторая строка – A ; третья строка – B .

Выходные данные: одно число – минимальная стоимость операций.

Sample Input:

1 1 1

entrance

reenterable

Sample Output:

5

Задание 2

Над строкой ϵ (будем считать строкой непрерывную последовательность из латинских букв) заданы следующие операции:

1. $\text{replace}(\epsilon, a, b)$ – заменить символ a на символ b .
2. $\text{insert}(\epsilon, a)$ – вставить в строку символ a (на любую позицию).

3. delete(ϵ , b) – удалить из строки символ b.

Каждая операция может иметь некоторую цену выполнения (положительное число).

Даны две строки A и B, а также три числа, отвечающие за цену каждой операции. Определите последовательность операций (редакционное предписание) с минимальной стоимостью, которые необходимы для превращения строки A в строку B.

М	М	М	Р	І	М	Р	Р
С	О	Н	Н		Е	С	Т
С	О	Н	Е	Н	Е	А	Д

Рисунок 1 - Пример, где все операции стоят одинаково

М	М	М	Д	М	І	І	І	І	Д	Д
С	О	Н	Н	Е					С	Т
С	О	Н		Е	Н	Е	А	Д		

Рисунок 2 - Пример, где цена замены 3, остальные операции по 1

Входные данные: первая строка – три числа: цена операции replace, цена операции insert, цена операции delete; вторая строка – A; третья строка – B.

Выходные данные: первая строка – последовательность операций (М – совпадение, ничего делать не надо; R – заменить символ на другой; I – вставить символ на текущую позицию; D – удалить символ из строки); вторая строка – исходная строка A; третья строка – исходная строка B.

Sample Input:

1 1 1

entrance

reenterable

Sample Output:

IMIMIMIMRRM

entrance

reenterable

Задание 3

Расстоянием Левенштейна назовем минимальное количество операций вставки одного символа, удаления одного символа и замены одного символа на другой, необходимых для превращения одной строки в другую. Разработайте программу, осуществляющую поиск расстояния Левенштейна между двумя строками.

Пример:

Для строк pedestal и stien расстояние Левенштейна равно 7:

- Сначала нужно совершить четыре операции удаления символа: pedestal -> stal.
- Затем необходимо заменить два последних символа: stal -> stie.
- Потом нужно добавить символ в конец строки: stie -> stien.

Параметры входных данных:

Первая строка входных данных содержит строку из строчных латинских букв. ($S, 1 \leq |S| \leq 2550$).

Вторая строка входных данных содержит строку из строчных латинских букв. ($T, 1 \leq |T| \leq 2550$).

Параметры выходных данных:

Одно число L , равное расстоянию Левенштейна между строками S и T .

Sample Input:

pedestal

stien

Sample Output:

7

Вариант 4б. Добавляется 4-я операция со своей стоимостью: замена двух символов на один символ.

Описание алгоритмов

Для решения задания лабораторной работы использовался алгоритм Вагнера-Фишера.

Алгоритм Вагнера-Фишера осуществляется в функции *def editorial_distance(str1: str, str2: str, cost_replace: int, cost_insert: int, cost_delete: int, cost_replace2: int) -> int* - вычисляет редакционное расстояние (с модификацией, включающей новую операцию замену двух символов на один) между двумя строками *str1* и *str2*. Функция заполняет матрицу редакционных расстояний для префиксов строк, но хранит только предыдущую и текущую строку для оптимизации памяти. Она инициализирует первую строку матрицы расстояний (стоимостями удалений) и затем итеративно заполняет остальные строки, используя функцию *distance_between_prefixes* для вычисления минимальной стоимости на каждом шаге. Функция выводит промежуточные результаты заполнения матрицы и возвращает итоговую минимальную стоимость, которая находится в последнем столбце последней строки матрицы расстояний.

def distance_between_prefixes(i: int, j: int, str1: str, str2: str, current_row: list, previous_row: list, cost_replace: int, cost_insert: int, cost_delete: int, cost_replace2: int) -> int - функция, которая вычисляет минимальную стоимость преобразования префикса строки *str1* длины *i* в префикс строки *str2* длины *j*. Она рассматривает три стандартные операции редактирования (вставка, удаление, замена) и дополнительную операцию замены двух символов в *str1* на один в *str2*. Функция возвращает минимальную стоимость и выводит на экран промежуточные результаты расчета.

Для вычисления минимальной стоимости преобразования префикса строки *str1* длины *i* в префикс строки *str2* длины *j* используется рекуррентная формула.

$$D(i, j) = \begin{cases} 0 & ; i = 0, j = 0 \\ i * deleteCost & ; j = 0, i > 0 \\ j * insertCost & ; i = 0, j > 0 \\ D(i - 1, j - 1) & ; S_1[i] = S_2[j] \\ \min (& \\ \quad D(i, j - 1) + insertCost & \\ \quad D(i - 1, j) + deleteCost & ; j > 0, i > 0, S_1[i] \neq S_2[j] \\ \quad D(i - 1, j - 1) + replaceCost & \\) & \end{cases}$$

$\min(a, b, c)$ возвращает наименьший из аргументов.

Рисунок 3 - Рекуррентная формула для алгоритма Вагнера-Фишера

Также для выполнения лабораторной работы был написан алгоритм нахождения редакционного предписания. Этот алгоритм осуществляется функцией - `def sequence_of_operations(str1: str, str2: str, cost_replace: int, cost_insert: int, cost_delete: int, cost_replace2: int) -> str`. Функция находит оптимальную последовательность операций в два этапа:

○ Построение матрицы стоимостей:

- Создается матрица размером $(\text{len}(\text{str2})+1) \times (\text{len}(\text{str1})+1)$
- Первая строка/столбец инициализируются стоимостями удаления/вставки(стоимость удаления i символов и вставки j символов)
- Каждая ячейка итеративно заполняется минимальной стоимостью из возможных операций функцией `distance_between_prefixes`

○ Восстановление пути:

- Обратный проход от `matrix[-1][-1]` к `matrix[0][0]`
- На каждом шаге определяется операция, давшая минимальную стоимость
- Операции записываются в обратном порядке ('T','D','R','T','M')
- Результат реверсируется для получения итоговой последовательности

Оценка сложности:

Алгоритм нахождения минимальной стоимости операций:

- По времени: $O(N*M)$, где N, M - длины строк. Обоснование - нужно заполнить матрицу расстояний префиксов строк, размером $N*M$
- По памяти: $O(2*N)$, где N - длина первой строки. Обоснование - храним только текущую и предыдущую строку.

Алгоритм нахождения редакционного предписания:

- По времени: $O(N*M)$, где N, M - длины строк. Обоснование - нужно заполнить матрицу расстояний префиксов строк, размером $N*M$. Цикл же `while` будет выполняться не более $(N + M)$ раз, так как на каждом шаге i или j уменьшается хотя бы на 1.
- По памяти: $O(N*M)$, где N, M - длины строк. Обоснование - нужно хранить всю матрицу расстояний префиксов, чтобы построить последовательность операций.

Тестирование

Результаты тестирования представлены в табл. 1.

Таблица 1 – Результаты тестирования

№ п/п	Входные данные	Выходные данные	Комментарии
1.	1 1 1 1 dom ro	2	Нахождение минимальной стоимости операций(<code>min_cost</code>): корректно (стоимость операций является случаем расстояния Левешнтейна)
2.	1 1 1 1 dom ro	TR	Нахождение редакционного предписания(<code>sequence</code>): корректно

3.	1 1 1 1 worker worker	0	min_cost: для одинаковых строк работает корректно.
4.	1 1 1 1 worker worker	MMMMMM	sequence: для одинаковых строк работает корректно.
5.	3 1 1 1 connect conehead	5	min_cost: для разных весов операций работает.
6.	3 1 1 1 connect conehead	МММШТТ	sequence: для разных весов операций работает.
7	2 2 1 1 connect conehead	7	min_cost: для разных весов операций работает.
8	2 2 1 1 connect conehead	МММІRМІТ	sequence: для разных весов операций работает.

Выводы

В ходе работы были успешно изучены задача о редакционном расстоянии, алгоритм Вагнера-Фишера и расстояние Левенштейна

ПРИЛОЖЕНИЕ А

ИСХОДНЫЙ КОД ПРОГРАММЫ

Название файла: main.py

```
import sys

def distance_between_prefixes(i: int, j: int, str1: str, str2: str,
current_row: list, previous_row: list,
                                cost_replace: int, cost_insert: int,
cost_delete: int, cost_replace2: int) -> int:
    replace2_cost = sys.maxsize
    replace2_possible = False

    if i >= 2:
        replace2_cost = previous_row[i - 2] + cost_replace2
        replace2_possible = True

    insertion_cost = previous_row[i] + cost_insert
    deletion_cost = current_row[i - 1] + cost_delete

    if str1[i - 1] == str2[j - 1]:
        substitution_cost = previous_row[i - 1]
    else:
        substitution_cost = previous_row[i - 1] + cost_replace

    # Формируем вывод
    output_lines = [
        f"Для префиксов строки 1 до {i} символа (i = {i}) и строки 2 до {j} символа (j = {j}):",
        f"стоимость, если последняя операция вставка = {insertion_cost}",
        f"стоимость, если последняя операция удаление = {deletion_cost}",
        f"стоимость, если последняя операция замена = {substitution_cost}"
    ]

    # Добавляем информацию о replace2_cost только если операция возможна
    if replace2_possible:
        output_lines.append(f"стоимость, если последняя операция замена двух символов на один = {replace2_cost}")
    else:
        output_lines.append("операция замены двух символов на один невозможна")

    min_cost = min(insertion_cost, deletion_cost, substitution_cost, replace2_cost)
    output_lines.append(f"МИНИМАЛЬНАЯ СТОИМОСТЬ = {min_cost}\n")

    # Промежуточный вывод
    print('\n'.join(output_lines))
    return min_cost
```

```

def editorial_distance(str1: str, str2: str, cost_replace: int,
cost_insert: int, cost_delete: int, cost_replace2: int) -> int:
    len1, len2 = len(str1), len(str2)
    current_row = [cost_delete * x for x in range(1 + len1)]
    print("Заполнение первой строки матрицы редакционных
расстояний(операция удаления)")
    print("Первая строка: " + ' '.join(map(str, current_row)))
    for j in range(1, len2 + 1):
        previous_row = current_row
        current_row = [j * cost_insert] + [0] * len1
        print(f"Для строки {j} первый столбец заполняется стоимостью
операций вставки = {current_row[0]}")
        for i in range(1, len1 + 1):
            current_row[i] = distance_between_prefixes(i, j, str1,
str2, current_row, previous_row, cost_replace, cost_insert, cost_delete,
cost_replace2)
    print("ИТОГОВАЯ СТОИМОСТЬ ОПЕРАЦИЙ")
    return current_row[len1]

def sequence_of_operations(str1: str, str2: str, cost_replace: int,
cost_insert: int, cost_delete: int, cost_replace2: int) -> str:
    len1, len2 = len(str1), len(str2)
    matrix = [[0] * (len1 + 1) for _ in range(len2 + 1)]
    print("Заполнение первой строки матрицы редакционных
расстояний(операция удаления)")
    for i in range(len1 + 1):
        matrix[0][i] = i * cost_delete
    print("Первая строка: " + ' '.join(map(str, matrix[0])))

    print("Заполнение первого столбца матрицы редакционных
расстояний(операция вставки)")
    column = ""
    for j in range(len2 + 1):
        matrix[j][0] = j * cost_insert
        column += str(matrix[j][0]) + " "
    print("Первый столбец: " + column + "\n")

    for j in range(1, len2 + 1):
        for i in range(1, len1 + 1):
            matrix[j][i] = distance_between_prefixes(i, j, str1,
str2, matrix[j], matrix[j-1], cost_replace, cost_insert, cost_delete,
cost_replace2)

    result = []

    list_str1 = [" ", " "] + list(str1)
    list_str2 = [" "] + list(str2)
    print("Получена матрица редакционных расстояний")
    print(" ".join(list_str1))
    for j in range(len2 + 1):
        string_matrix = f"{list_str2[j]} "
        for i in range(len1 + 1):
            string_matrix += str(matrix[j][i]) + " "
        print(string_matrix)

    print("\nВосстановление операций, начиная с конца")
    i, j = len1, len2

```

```

while i > 0 or j > 0:
    if i == 0:
        result.append('I')
        j -= 1
        print(f"Операция: вставка(I), перемещаемся на позицию j =
{j} i = {i}")
    elif j == 0:
        result.append('D')
        i -= 1
        print(f"Операция: удаление(D), перемещаемся на позицию j
= {j} i = {i}")
    else:
        current = matrix[j][i]
        if str1[i - 1] == str2[j - 1] and current == matrix[j -
1][i - 1]:
            result.append('M')
            i -= 1
            j -= 1
            print(f"Операция: совпадение(M), перемещаемся на
позицию j = {j} i = {i}")
        elif current == matrix[j - 1][i - 1] + cost_replace:
            result.append('R')
            i -= 1
            j -= 1
            print(f"Операция: замена(R), перемещаемся на позицию
j = {j} i = {i}")
        elif i >= 2 and current == matrix[j - 1][i - 2] +
cost_replace2:
            result.append('T')
            i -= 2
            j -= 1
            print(f"Операция: замена двух символов на один(T),
перемещаемся на позицию j = {j} i = {i}")
        elif current == matrix[j][i - 1] + cost_delete:
            result.append('D')
            i -= 1
            print(f"Операция: удаление(D), перемещаемся на
позицию j = {j} i = {i}")
        else:
            result.append('I')
            j -= 1
            print(f"Операция: вставка(I), перемещаемся на
позицию j = {j} i = {i}")

print("\nИТОГОВАЯ ПОСЛЕДОВАТЕЛЬНОСТЬ ОПЕРАЦИЙ")
return ''.join(reversed(result))

if __name__ == "__main__":
    print("Редакционное расстояние - нахождение минимальной стоимости
операций")
    cost_replace, cost_insert, cost_delete, cost_replace2 = map(int,
input().split(' '))
    str1 = input()
    str2 = input()
    print(editorial_distance(str1, str2, cost_replace, cost_insert,
cost_delete, cost_replace2))
    print("\nРедакционное расстояние - нахождение последовательности
операций")

```

```
    print(sequence_of_operations(str1, str2, cost_replace, cost_insert,  
cost_delete, cost_replace2))
```